

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
ІМЕНІ ІГОРЯ СІКОРСЬКОГО»

Факультет прикладної математики

Кафедра прикладної математики

Звіт
із лабораторної роботи №3
з дисципліни «Системи нейронних мереж»
на тему
«Нейромережеве розпізнавання кібератак»

Виконав:
студент групи КМ-02
Пилипченко Б. О.

Керівник:
Терейковський І. А.

Мета роботи:

Розробка програмного забезпечення для реалізації нейронної мережі PNN, призначеної для розпізнавання кібератак, сигнатури яких представлені у базах даних KDD-99.

Теоретичні відомості:

Роберт Каллан Основні концепції нейронних мереж ст. 152—164

Архітектура мережі

PNN мережа складається з трьох шарів:

1. Вхідний шар:

Вхідний шар розподіляє характеристики вхідного зразка на шар зразків. Кожен нейрон вхідного шару пов'язаний із кожним нейроном шару зв'язків.

2. Шар зразків:

Шар зразків має по одному нейрону для кожного зразка. Вагові коефіцієнти вхідних сигналів нейрону дорівнюють значенням характеристик відповідного зразка.

Функція активації нейрону шару зразків:

$$O_j = \exp\left(\frac{-\sum (w_{ij} - x_i)^2}{\sigma^2}\right)$$

O_j —характеристика близькості вхідного зразка до j -того зразка класу;

x_i — i -та характеристика вхідного зразка;

w_{ij} — i -та характеристика j -того зразка класу;

σ —параметр мережі.

3. Шар класів:

Шар класів має по одному нейрону для кожного класу. Кожен нейрон шару класів має зв'язки лише з нейронами зв'язків, які належать до класу. Всі вагові коефіцієнти між шаром зразків та шаром класів рівні 1.

Функція активації нейрону шару класів є сумою вхідних сигналів нейрону.

PNN мережа не потребує навчання, подібного до навчання мереж із оберненим поширенням сигналу. Всі параметри мережі PNN, крім значення сігми, визначаються безпосередньо навчальними даними:


Кількість нейронів вхідного шару = кількість характеристик зразків

Кількість нейронів шару зразків = кількість зразків

Кількість нейронів шару класів = кількість класів

Навчання мережі полягає у підборі оптимального значення сігми.

В роботі сігма підбиралась експериментально.



Огляд даних

В якості датасету було обрано [KDD99](#). Остаточне тестування мереж здійснювалось на всьому датасеті (490020 зразків).

Початковий датасет містить 42 колонки (41 ознака + label):

```
>>> Column types >>>
duration                int64
protocol_type           object
service                 object
flag                   object
src_bytes               int64
dst_bytes               int64
land                    int64
wrong_fragment          int64
urgent                  int64
hot                     int64
num_failed_logins       int64
logged_in               int64
lnum_compromised         int64
lroot_shell             int64
lsu_attempted           int64
lnum_root               int64
lnum_file_creations      int64
lnum_shells              int64
lnum_access_files        int64
lnum_outbound_cmds       int64
is_host_login            int64
is_guest_login           int64
count                   int64
srv_count                int64
serror_rate              float64
srv_serror_rate          float64
rerror_rate              float64
srv_rerror_rate          float64
same_srv_rate            float64
diff_srv_rate            float64
srv_diff_host_rate       float64
dst_host_count           int64
dst_host_srv_count       int64
dst_host_same_srv_rate   float64
dst_host_diff_srv_rate   float64
dst_host_same_src_port_rate float64
dst_host_srv_diff_host_rate float64
dst_host_serror_rate     float64
dst_host_srv_serror_rate float64
dst_host_rerror_rate     float64
dst_host_srv_rerror_rate float64
label                    object
```

Колонки lnum_outbound_cmds, is_host_login дорівнюють нулю для всіх зразків у датасеті:

Column: lnum_outbound_cmds
Unique Values Count: 1
Unique Values: [0]

Column: is_host_login
Unique Values Count: 1
Unique Values: [0]

тому було вирішено видалити ці колонки для всіх зразків. Остаточний датасет має 39 ознак.

В датасеті наявні ознаки, значеннями яких є рядкові літерали. Для таких ознак було застосовано LabelEncoder із бібліотеки sklearn. Таким чином нечислові ознаки було перетворено на числові, значення яких змінюється від 0 до n-1, де n—кількість унікальних значень ознаки.

Останнім кроком перед розбиттям даних на тренувальну та тестувальну вибірки є нормалізація значень ознак.

Розбиття даних

Параметри розбиття:

PNN_REFERENCE_COUNT_BY_CLASS	Набір пар «назва класу» - кількість прикладів класу rnp мережі відносно тренувальної вибірки
TEST_SIZE	Розмір тестової вибірки відносно вхідного (обробленого) датасету
REAL_DATA_COUNT_PER_CLASS	Максимальна кількість зразків класу в rnp мережі. Якщо кількість зразків класу перевищує параметр, то із всіх зразків класу обирається REAL_DATA_COUNT_PER_CLASS зразків випадковим чином.
RANDOM_STATE	Єдине значення random_state для всіх функцій, що потребують встановлення зерна.

Приклад набору параметрів:

```
PNN_REFERENCE_COUNT_BY_CLASS = {
    "smurf": 0.6,
    "neptune": 0.6,
    "normal": 0.6,
    "back": 1.0,
    "satan": 1.0,
    "ipsweep": 1.0,
    "portsweep": 1.0,
    "warezclient": 1.0,
    "teardrop": 1.0,
    "pod": 1.0,
    "nmap": 1.0,
    "guess_passwd": 1.0,
    "buffer_overflow": 1.0,
    "land": 1.0,
    "warezmaster": 1.0,
    "imap": 1.0,
    "rootkit": 1.0,
    "loadmodule": 1.0,
    "ftp_write": 1.0,
    "multihop": 1.0,
    "phf": 1.0,
    "perl": 1.0,
    "spy": 1.0
}
TEST_SIZE = 0.25
REAL_DATA_COUNT_PER_CLASS = 150
RANDOM_STATE = 1450
```

Розбиття обробленого датасету на тренувальну та навчальну вибірки виконується наступним чином:

1. Оброблений датасет розбивається на «елементарні» датасети—кожен елементарний датасет містить всі зразки одного класу, лише зразки одного класу.
2. Для кожного елементарного датасету: кроки 3 або 4
3. Якщо кількість записів у елементарному датасеті менша за REAL_DATA_COUNT_PER_CLASS—всі записи елементарного датасету заносяться у rnp мережу, навчальну вибірку, тестову вибірку.
4. Якщо кількість записів у елементарному датасеті більша за REAL_DATA_COUNT_PER_CLASS, тоді береться випадкова вибірка з елементарного датасету розміром REAL_DATA_COUNT_PER_CLASS. Отримана вибірка розбивається на тренувальну та тестову вибірки у співвідношенні TEST_SIZE. Далі із тренувальної вибірки обираються приклади, що будуть занесені у власне rnp мережу у співвідношенні, заданому PNN_REFERENCE_COUNT_BY_CLASS.
5. Внаслідок кроків 3, 4 отримуємо 3 набори даних для кожного класу: rnp набір, тренувальний набір, тестовий набір. Виконується об'єднання відповідних наборів у кінцеві rnp дані, тренувальні дані, тестові дані.

Навчання мережі

Тренувальні, тестові вибірки, текстові представлення pnn мереж: [MLDL-lab3](https://github.com/Bohdan628318ylypchenko/MLDL-Lab3)

Код скрипта-генератора даних, реалізації PNN: <https://github.com/Bohdan628318ylypchenko/MLDL-Lab3.git>

Параметри генерації PNN, тестової вибірки, валідаційної вибірки:

```
PNN_REFERENCE_COUNT_BY_CLASS = {
    "smurf": 0.6,
    "neptune": 0.6,
    "normal": 0.6,
    "back": 1.0,
    "satan": 1.0,
    "ipsweep": 1.0,
    "portsweep": 1.0,
    "warezclient": 1.0,
    "teardrop": 1.0,
    "pod": 1.0,
    "nmap": 1.0,
    "guess_passwd": 1.0,
    "buffer_overflow": 1.0,
    "land": 1.0,
    "warezmaster": 1.0,
    "imap": 1.0,
    "rootkit": 1.0,
    "loadmodule": 1.0,
    "ftp_write": 1.0,
    "multihop": 1.0,
    "phf": 1.0,
    "perl": 1.0,
    "spy": 1.0
}
TEST_SIZE = 0.25
REAL_DATA_COUNT_PER_CLASS = 2000
RANDOM_STATE_1 = 1450
RANDOM_STATE_2 = 860
```

Остаточні дані можна переглянути в репозиторії (файли pnn-2000.txt, train-2000.txt, test-2000.txt)

Початкове значення $s = 0.01$

Запуск мережі на тренувальній вибірці:

```
t
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 1.00000000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 1.00000000000000000000
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 0.9993750000000001332
Class: nmap-231; eval: 0.98701298701298700866
Class: normal-960; eval: 0.9575000000000001776
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 1.00000000000000000000
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 3.097883
```

Запуск мережі на тестовій вибірці:

```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 1.00000000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 1.00000000000000000000
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 0.99750000000000005329
Class: nmap-231; eval: 0.98701298701298700866
Class: normal-960; eval: 0.8950000000000001776
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 1.00000000000000000000
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 0.99750000000000005329
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
```

Спробуємо запустити мережу на кожному прикладі класу `multihop` окремо:

[illegible][illegible]

Результат роботи мережі, s = 0.001

Тренувальна вибірка:

```
t
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.93333333333333334814
Class: ftp_write-8; eval: 1.00000000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 1.00000000000000000000
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 1.00000000000000000000
Class: neptune-960; eval: 0.95437499999999997335
Class: nmap-231; eval: 1.00000000000000000000
Class: normal-960; eval: 0.78812499999999996447
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 1.00000000000000000000
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 4.042179
```

Тестова вибірка:

```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.93333333333333334814
Class: ftp_write-8; eval: 1.00000000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 1.00000000000000000000
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 1.00000000000000000000
Class: neptune-960; eval: 0.87500000000000000000
Class: nmap-231; eval: 1.00000000000000000000
Class: normal-960; eval: 0.48249999999999998446
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 1.00000000000000000000
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 0.997500000000000005329
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2.273892
```

Мережа змогла перенавчитись, для обох вибірок правильно класифікує всі приклади multihop. При цьому результати розпізнавання інших класів очікувано погіршились (клас normal (s = 0.01) t: 0.9575; v: 0.895 проти (s = 0.001) t: 0.7881; v: 0.4824 | клас neptune (s = 0.01) t: 0.9993; v: 0.9975 проти (s = 0.001) t: 0.9543; v: 0.8750). Враховуючи кількість зразків класу normal (97277 у початковому датасеті), не має сенсу розпізнавати всі приклади multihop за рахунок 0.4824 правильних відповідей для класу normal.

Оберемо сігму рівній 0.1

Результат роботи мережі, s = 0.1

Тренувальна вибірка:

```
t
Class: back-1600; eval: 0.99875000000000002665
Class: buffer_overflow-30; eval: 0.766666666666666671848
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99438652766639934466
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.98701298701298700866
Class: normal-960; eval: 0.80500000000000004885
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.80000000000000004441
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2.449062
```

Тестова вибірка:

```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.766666666666666671848
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99438652766639934466
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.98701298701298700866
Class: normal-960; eval: 0.76249999999999995559
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.80000000000000004441
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 1.756200
```


Мережа є більш точною при $s = 0.1$ аніж при $s = 0.001$. При цьому результати для $s = 0.1$ гірші за результати для $s = 0.01$ (наприклад клас `buffer_overflow-30` ($s = 0.1$) t : 0.7666; v : 0.7666 проти ($s = 0.01$) t : 0.9000; v : 0.9000).
Отже оптимальна сігма знаходиться в межах (0.01; 0.1).

Протестуємо мережу для значень сігми (0.015, 0.025, 0.035, 0.045):

$s = 0.015$

```
t
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 1.00000000000000000000
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 0.99937500000000001332
Class: nmap-231; eval: 0.98701298701298700866
Class: normal-960; eval: 0.96937499999999998668
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 3.141179
```

```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 1.00000000000000000000
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.98701298701298700866
Class: normal-960; eval: 0.92500000000000004441
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2.272826
```

$s = 0.025$

```
t
Class: back-1600; eval: 0.99937500000000001332
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99919807538091420795
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.97624999999999995115
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 3.096189
```

```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99919807538091420795
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.93500000000000005329
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2.230893
```

$s = 0.035$

```

t
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99759422614274262386
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.97875000000000000888
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 3.171035

```

 $s = 0.045$

```
t
Class: back-1600; eval: 0.998750000000000002665
Class: buffer_overflow-30; eval: 0.900000000000000002220
Class: ftp_write-8; eval: 0.875000000000000000000
Class: guess_passwd-53; eval: 1.000000000000000000000
Class: imap-12; eval: 1.000000000000000000000
Class: ipsweep-1247; eval: 0.99679230152365672080
Class: land-21; eval: 1.000000000000000000000
Class: loadmodule-9; eval: 1.000000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.000000000000000000000
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.978125000000000002220
Class: perl-3; eval: 1.000000000000000000000
Class: phf-4; eval: 1.000000000000000000000
Class: pod-264; eval: 1.000000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.900000000000000002220
Class: satan-1589; eval: 1.000000000000000000000
Class: smurf-960; eval: 1.000000000000000000000
Class: spy-2; eval: 1.000000000000000000000
Class: teardrop-979; eval: 1.000000000000000000000
Class: warezclient-1020; eval: 1.000000000000000000000
Class: warezmaster-20; eval: 1.000000000000000000000
zero count: 0
time: 3.217059
```


```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99759422614274262386
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.95250000000000001332
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2.225466
```

```


Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99679230152365672080
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 1.00000000000000000000
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.94999999999999995559
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 1.00000000000000000000
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2.195528

```

Train dataset results by sigma



Test dataset results by sigma



Виходячи з наведених графіків, в якості оптимального значення сігми було обрано 0.035.
Протестуємо мережу на всьому датасеті:

```
v
Class: back-1600; eval: 1.00000000000000000000
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99759422614274262386
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-960; eval: 0.99978544976259553501
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-960; eval: 0.95845883405121456988
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.9000000000000000002220
Class: satan-1589; eval: 1.00000000000000000000
Class: smurf-960; eval: 0.99919868941201606116
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 143.127316
```

На всіх класах, крім ftp_write, multihop, buffer_overflow, rootkit маємо точність, більшу за 95%. На інших класах точність є не меншою за 85%.

Окремо варто виділити той факт, що тестування мережі, загальна кількість зразків в якій дорівнює 11029, на датасеті розміром 494020 зразків, зайняло всього лиш ~143 секунди.

В оригінальному датасеті клас normal містить 97277 зразків. Клас normal відповідає нормальному трафіку. В наведеній нейронній мережі наявно лише 960 зразків класу normal. Значення характеристик зразків, що належать класу normal, можуть сильно варіюватись, оскільки характер «нормального» трафіку визначається лише діями користувачів. Збільшимо кількість зразків класу normal до 3600 (за рахунок зміни значення REAL_DATA_COUNT_PER_CLASS, зміна цього параметра також впливає на кількість прикладів у rnn для інших класів).

Параметри генерації даних:

```
PNN_REFERENCE_COUNT_BY_CLASS = {
    "smurf": 0.6,
    "neptune": 0.6,
    "normal": 0.6,
    "back": 1.0,
    "satan": 1.0,
    "ipsweep": 1.0,
    "portsweep": 1.0,
    "warezclient": 1.0,
    "teardrop": 1.0,
    "pod": 1.0,
    "nmap": 1.0,
    "guess_passwd": 1.0,
    "buffer_overflow": 1.0,
    "land": 1.0,
    "warezmaster": 1.0,
    "imap": 1.0,
    "rootkit": 1.0,
    "loadmodule": 1.0,
    "ftp_write": 1.0,
    "multihop": 1.0,
    "phf": 1.0,
    "perl": 1.0,
    "spy": 1.0
}
TEST_SIZE = 0.25
REAL_DATA_COUNT_PER_CLASS = 8000
RANDOM_STATE_1 = 1450
```

v
Class: back-2203; eval: 0.99954607353608715403
Class: buffer_overflow-30; eval: 0.90000000000000002220
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99759422614274262386
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.85714285714285709528
Class: neptune-3600; eval: 0.99977612149140404618
Class: nmap-231; eval: 0.97835497835497831076
Class: normal-3600; eval: 0.98229797382731787181
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99903846153846154188
Class: rootkit-10; eval: 0.90000000000000002220
Class: satan-1589; eval: 0.99937067337948393142
Class: smurf-3600; eval: 0.99949784536486341313
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 1.00000000000000000000
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 240.441858

Спостерігаємо очікуване покращення результату для класу normal:
0.98229797382731787181 (3600 зразків normal) проти 0.95845883405121456988 (960 зразків normal).

Текстове представлення остаточної мережі—файл pnn-8000.txt у репозиторії.

Варто зауважити, що мережа помилково розпізнає деякі приклади класів малої розмірності (buffer_overflow, ftp_write, multihop, rootkit). В роботі було показано що показники розпізнавання таких класів можна покращити, значно зменшивши сігму. Але в такому випадку значно погіршуються показники «основних» класів.

Лог процесу навчання—файл report-session.txt у репозиторії.

Окремо хотілось виділити швидкодію мережі:
Розпізнавання 494020 зразків мережею, що містить 11029 зразків, займає 143 секунди. Розпізнавання одного зразка— ~1.5 мілісекунд.
Розпізнавання 494020 зразків мережею, що містить 19552 зразків, займає 240 секунди. Розпізнавання одного зразка— ~2.8 мілісекунд.

Тестування здійснювалось на процесорі Intel Core I5-8250U (1.6GHz—3.4GHz, 4 cores / 8 threads).

Таким чином використання мови C та технології OpenMP для реалізації мережі є виправданим.

p.s.

Як виявилось, за посиланням [Kddcup99 - Dataset - DataHub - Frictionless Data](#)—лише вибірка розміром 10% із оригінального датасету KDD99. Оригінальний датасет Kdd99 можна знайти за посиланням: [KDD Cup 1999 Data \(uci.edu\)](#). Цей датасет містить 4898431 зразків.

Кількість зразків кожного класу в датасеті:

```
>>> Class | Count >>>
```

```

label
smurf      2807886
neptune    1072017
normal     972781
satan      15892
ipsweep    12481
portswEEP  10413
nmap       2316
back       2203
warezclient 1020
teardrop   979
pod        264
guess_passwd 53
buffer_overflow 30
land       21
warezmaster 20
imap       12
rootkit    10
loadmodule 9
ftp_write  8
multihop   7
phf        4
perl       3
spy        2
Name: count, dtype: int64

```

Протестуємо остаточну мережу (представлення—файл `rnn-8000.txt` у репозиторії) на всіх ~4.8М прикладів. Результат:

```
v
Class: back-2203; eval: 0.99773036768043577016
Class: buffer_overflow-30; eval: 0.86666666666666669627
Class: ftp_write-8; eval: 0.87500000000000000000
Class: guess_passwd-53; eval: 1.00000000000000000000
Class: imap-12; eval: 1.00000000000000000000
Class: ipsweep-1247; eval: 0.99679512859546515191
Class: land-21; eval: 1.00000000000000000000
Class: loadmodule-9; eval: 1.00000000000000000000
Class: multihop-7; eval: 0.71428571428571430157
Class: neptune-3600; eval: 0.99978171987944219889
Class: nmap-231; eval: 0.96243523316062173922
Class: normal-3600; eval: 0.98279880055223123314
Class: perl-3; eval: 1.00000000000000000000
Class: phf-4; eval: 1.00000000000000000000
Class: pod-264; eval: 1.00000000000000000000
Class: portsweep-1040; eval: 0.99654278305963694962
Class: rootkit-10; eval: 0.90000000000000000220
Class: satan-1589; eval: 0.99496602063931538495
Class: smurf-3600; eval: 0.99951743055095543244
Class: spy-2; eval: 1.00000000000000000000
Class: teardrop-979; eval: 1.00000000000000000000
Class: warezclient-1020; eval: 0.85882352941176465233
Class: warezmaster-20; eval: 1.00000000000000000000
zero count: 0
time: 2349.750440
```

Точність розпізнавання прикладів мережею є задовільна: для більшості класів точність є більшою за 95%. Винятком є класи ftp, write, multihop, warezclient.

В якості подальших покращень можна запропонувати незначно збільшити кількість зразків класу `warezclient` в мережі. Враховуючи, що всі приклади класів `ftp_write` та `multihop` наявні в мережі (7 та 8 прикладів відповідно), покращити результати розпізнавання цих класів можна лише зменшивши `sigmu`—але тоді значно погіршаться показники інших класів.

Окремо варто відмітити, що мережа розміром 19552 зразків розпізнала $\sim 4.8\text{M}$ прикладів за $2349.750440 / 60 = \sim 39.16$ хвилин.

Selected files

7 printable files

pnnlib\pch.c
pnnlib\pch.h
pnnlib\pnn_alloc_check.h
pnnlib\pnn_core.c
pnnlib\pnn_io.c
pnnlib\pnn_memory.c
pnnlib\pnn.h

pnnlib\pch.c

```
1 // pch.c: source file corresponding to the pre-compiled header
2
3 #include "pch.h"
4
5 // When you are using pre-compiled headers, this source file is necessary for compilation to
  succeed.
6
```

pnnlib\pch.h

```
1 // pch.h: This is a precompiled header file.
2 // Files listed below are compiled only once, improving build performance for future builds.
3 // This also affects IntelliSense performance, including code completion and many code
  browsing features.
4 // However, files listed here are ALL re-compiled if any one of them is updated between
  builds.
5 // Do not add files here that you will be updating frequently as this negates the performance
  advantage.
6
7 #ifndef PCH_H
8 #define PCH_H
9
10 #include "pnn.h"
11 #include "pnn_alloc_check.h"
12
13 #endif //PCH_H
14
```

pnnlib\pnn_alloc_check.h

```
1 #pragma once
2
3 #include <stdio.h>
4 #include <stdlib.h>
5
6 /// <summary>
7 /// Macros to check for memory allocation fail.
8 /// </summary>
9 #define ALLOC_ERR_MSG "Error: memory allocation failed.\n"
```

```

10 #define pnn_fail_alloc_check(p)\
11 {\
12     if (p == NULL)\
13     {\
14         fprintf(stderr, ALLOC_ERR_MSG);\
15         abort();\
16     }\
17 }
18
19

```

pnnlib\pnn_core.c

```

1  #include "pch.h"
2
3  #include "pnn.h"
4
5  #include "pnn_alloc_check.h"
6
7  #include <stdlib.h>
8  #include <math.h>
9  #include <omp.h>
10 #include <string.h>
11
12 #define MAX_SINGLE_THREAD 250
13
14 static double act(int property_count, pnn_reference * reference, double * input, double
sigma);
15 static int index_of_largest_prediction(int n, pnn_prediction * prediction_arr);
16 static int are_class_names_equal(char * class_name1, char * class_name2);
17
18 pnn_prediction * pnn_predict(pnn_data * net, double * input)
19 {
20     pnn_prediction * prediction_arr = (pnn_prediction *)malloc(net->class_count *
sizeof(pnn_prediction));
21     pnn_fail_alloc_check(prediction_arr);
22
23     for (int i = 0; i < net->class_count; i++)
24     {
25         pnn_class * current_class = net->pnn_class_arr[i];
26
27         prediction_arr[i].class_name = current_class->class_name;
28         prediction_arr[i].prediction = 0;
29
30         for (int j = 0; j < current_class->reference_count; j++)
31         {
32             prediction_arr[i].prediction += act(net->property_count,
33             current_class->reference_arr[j], input, net->
sigma);
34         }
35     }
36
37     return prediction_arr;
38 }
39

```



```

40 pnn_evaluation * pnn_evaluate(pnn_data * net, pnn_data * data)
41 {
42     pnn_evaluation * evaluation_arr = (pnn_evaluation *)malloc(data->class_count *
sizeof(pnn_evaluation));
43     pnn_fail_alloc_check(evaluation_arr);
44
45     for (int i = 0; i < data->class_count; i++)
46     {
47         pnn_class * current_class = data->pnn_class_arr[i];
48         pnn_evaluation * current_evaluation = &(amp;evaluation_arr[i]);
49
50         current_evaluation->class_name = current_class->class_name;
51         current_evaluation->accuracy = 0;
52
53         if (current_class->reference_count > MAX_SINGLE_THREAD)
54         {
55             double acc = 0;
56             int j;
57             #pragma omp parallel for reduction(+:acc)
58             for (j = 0; j < current_class->reference_count; j++)
59             {
60                 pnn_reference * current_reference = current_class->reference_arr[j];
61
62                 pnn_prediction * prediction_arr = pnn_predict(net, current_reference->
reference);
63                 int k = index_of_largest_prediction(net->class_count, prediction_arr);
64
65                 if (are_class_names_equal(current_class->class_name, prediction_arr[k]
.class_name) == 0)
66                     acc += 1.0;
67
68                 free(prediction_arr);
69             }
70
71             current_evaluation->accuracy = acc / (double)(current_class->reference_count);
72         }
73         else
74         {
75             for (int j = 0; j < current_class->reference_count; j++)
76             {
77                 pnn_reference * current_reference = current_class->reference_arr[j];
78
79                 pnn_prediction * prediction_arr = pnn_predict(net, current_reference->
reference);
80                 int k = index_of_largest_prediction(net->class_count, prediction_arr);
81
82                 if (are_class_names_equal(current_class->class_name, prediction_arr[k]
.class_name) == 0)
83                     current_evaluation->accuracy += 1.0;
84
85                 free(prediction_arr);
86             }
87
88             current_evaluation->accuracy /= (double)(current_class->reference_count);
89         }
90     }
91 }

```

```

92     return evaluation_arr;
93 }
94
95 static double act(int property_count, pnn_reference * reference, double * input, double
sigma)
96 {
97     double acc = 0, d;
98     for (int i = 0; i < property_count; i++)
99     {
100         d = reference->reference[i] - input[i];
101         acc += d * d;
102     }
103     acc /= -(sigma * sigma);
104
105     return exp(acc);
106 }
107
108 static int index_of_largest_prediction(int n, pnn_prediction * prediction_arr)
109 {
110     int i = 0;
111     for (int j = 0; j < n; j++)
112     {
113         if (prediction_arr[i].prediction < prediction_arr[j].prediction)
114             i = j;
115     }
116     return i;
117 }
118
119 static int are_class_names_equal(char * class_name1, char * class_name2)
120 {
121     char * dash1 = strchr(class_name1, '-');
122     char * dash2 = strchr(class_name2, '-');
123
124     size_t n = dash1 - class_name1;
125     if (n != dash2 - class_name2)
126         return 1;
127
128     return strncmp(class_name1, class_name2, n);
129 }
130

```

pnnlib\pnn_io.c

```

1  #include "pch.h"
2
3  #include "pnn.h"
4
5  #include "pnn_alloc_check.h"
6
7  #include <stdio.h>
8  #include <stdlib.h>
9
10 pnn_data * pnn_data_load(FILE * f)
11 {
12     int property_count;

```

```

13     int total_reference_count;
14     int class_count;
15
16     fread(&property_count, sizeof(int), 1, f);
17     fread(&total_reference_count, sizeof(int), 1, f);
18     fread(&class_count, sizeof(int), 1, f);
19
20     pnn_class ** pnn_class_arr = (pnn_class **)malloc(class_count * sizeof(pnn_class *));
21     pnn_fail_alloc_check(pnn_class_arr);
22     for (struct
23         {
24             int i;
25             size_t class_name_len; char * class_name;
26             int reference_count;
27         }
28     state_class = { .i = 0, .class_name_len = 0, .class_name = NULL, .reference_count =
0 };
29     state_class.i < class_count;
30     state_class.i++)
31     {
32         fread(&(state_class.class_name_len), sizeof(size_t), 1, f);
33
34         state_class.class_name = (char *)malloc((state_class.class_name_len + 1) *
sizeof(char));
35         pnn_fail_alloc_check(state_class.class_name);
36         fread(state_class.class_name, sizeof(char), state_class.class_name_len, f);
37         state_class.class_name[state_class.class_name_len] = '\0';
38
39         fread(&(state_class.reference_count), sizeof(int), 1, f);
40
41         pnn_reference ** pnn_reference_arr =
42             (pnn_reference **)malloc(state_class.reference_count * sizeof(pnn_reference *));
43         pnn_fail_alloc_check(pnn_reference_arr);
44         for (struct
45             {
46                 int j;
47                 int reference_id; int property_count;
48                 double * reference;
49             }
50     state_reference = { .j = 0, .reference_id = 0, .property_count = 0, .reference =
NULL};
51     state_reference.j < state_class.reference_count;
52     state_reference.j++)
53     {
54         fread(&(state_reference.reference_id), sizeof(int), 1, f);
55         fread(&(state_reference.property_count), sizeof(int), 1, f);
56
57         state_reference.reference = (double *)malloc(state_reference.property_count *
sizeof(double));
58         pnn_fail_alloc_check(state_reference.reference);
59         fread(state_reference.reference, sizeof(double), state_reference.property_count,
f);
60
61         pnn_reference_arr[state_reference.j] =
pnn_reference_create(state_reference.reference_id, state_reference.property_count,
62     state_reference.reference);
63     }

```

```

64
65     pnn_class_arr[state_class.i] = pnn_class_create(state_class.class_name,
66     state_class.reference_count, pnn_reference_arr);
67 }
68     pnn_data * data = pnn_data_create(DEFAULT_SIGMA, property_count, total_reference_count,
69     class_count,
70     pnn_class_arr);
71     return data;
72 }
73
74 void pnn_data_fprint(pnn_data * data, FILE * f)
75 {
76     fprintf(f, "sigma = %lf; property_count = %d; total_reference_count = %d; class_count =
77     %d\n",
78     data->sigma, data->property_count, data->total_reference_count, data->
79     class_count);
80
81     for (struct
82     {
83         int i;
84         pnn_class * current_class;
85     }
86     state_class = { .i = 0, .current_class = NULL };
87     state_class.i < data->class_count; state_class.i++)
88     {
89         state_class.current_class = data->pnn_class_arr[state_class.i];
90
91         fprintf(f, "    class_name = %s; reference_count = %d\n",
92         state_class.current_class->class_name, state_class.current_class->
93         reference_count);
94
95         for (struct
96         {
97             int j;
98             pnn_reference * current_reference;
99         }
100         state_reference = { .j = 0, .current_reference = NULL };
101         state_reference.j < state_class.current_class->reference_count;
102         state_reference.j++)
103         {
104             state_reference.current_reference = state_class.current_class->
105             reference_arr[state_reference.j];
106
107             fprintf(f, "        id = %d; property_count = %d; ",
108             state_reference.current_reference->id, state_reference.current_reference->
109             property_count);
110
111             for (int k = 0; k < state_reference.current_reference->property_count - 1; k++)
112             {
113                 fprintf(f, "%.2lf, ", state_reference.current_reference->reference[k]);
114             }
115             fprintf(f, "%.2lf\n", state_reference.current_reference->
116             reference[state_reference.current_reference->property_count - 1]);
117         }
118     }
119 }

```

113 |

pnnlib\pnn_memory.c

```
1  #include "pch.h"
2
3  #include "pnn.h"
4
5  #include "pnn_alloc_check.h"
6
7  #include <stdlib.h>
8
9  pnn_reference * pnn_reference_create(int id, int property_count, double * reference)
10 {
11     pnn_reference * obj = (pnn_reference *)malloc(sizeof(pnn_reference));
12     pnn_fail_alloc_check(obj);
13
14     obj->id = id;
15     obj->property_count = property_count;
16     obj->reference = reference;
17
18     return obj;
19 }
20
21 pnn_reference * pnn_reference_free(pnn_reference * obj)
22 {
23     free(obj->reference);
24     free(obj);
25
26     return NULL;
27 }
28
29 pnn_class * pnn_class_create(char * class_name, int reference_count, pnn_reference **
reference_arr)
30 {
31     pnn_class * obj = (pnn_class *)malloc(sizeof(pnn_class));
32     pnn_fail_alloc_check(obj);
33
34     obj->class_name = class_name;
35     obj->reference_count = reference_count;
36     obj->reference_arr = reference_arr;
37
38     return obj;
39 }
40
41 pnn_class * pnn_class_free(pnn_class * obj)
42 {
43     free(obj->class_name);
44     for (int i = 0; i < obj->reference_count; i++)
45         pnn_reference_free(obj->reference_arr[i]);
46     free(obj);
47
48     return NULL;
49 }
50
```

```

51 pnn_data * pnn_data_create(double sigma, int property_count, int total_reference_count, int
    class_count,
52                               pnn_class ** pnn_class_arr)
53 {
54     pnn_data * obj = (pnn_data *)malloc(sizeof(pnn_data));
55     pnn_fail_alloc_check(obj);
56
57     obj->sigma = sigma;
58     obj->property_count = property_count;
59     obj->total_reference_count = total_reference_count;
60     obj->class_count = class_count;
61     obj->pnn_class_arr = pnn_class_arr;
62
63     return obj;
64 }
65
66 pnn_data * pnn_data_free(pnn_data * obj)
67 {
68     for (int i = 0; i < obj->class_count; i++)
69         pnn_class_free(obj->pnn_class_arr[i]);
70     free(obj);
71
72     return NULL;
73 }
74

```

pnnlib\pnn.h

```

1  #pragma once
2
3  #include <stdio.h>
4
5  #define DEFAULT_SIGMA 0.01
6  #define EPSILON 0.001
7
8  typedef struct pnn_reference
9  {
10     int id;
11     int property_count;
12     double * reference;
13 } pnn_reference;
14
15 typedef struct pnn_class
16 {
17     char * class_name;
18     int reference_count;
19     struct pnn_reference ** reference_arr;
20 } pnn_class;
21
22 typedef struct pnn_data
23 {
24     double sigma;
25     int property_count;
26     int total_reference_count;
27     int class_count;

```

```
28     struct pnn_class ** pnn_class_arr;
29 }pnn_data;
30
31 pnn_reference * pnn_reference_create(int id, int property_count, double * reference);
32 pnn_reference * pnn_reference_free(pnn_reference * obj);
33
34 pnn_class * pnn_class_create(char * class_name, int reference_count, pnn_reference **
reference_arr);
35 pnn_class * pnn_class_free(pnn_class * obj);
36
37 pnn_data * pnn_data_create(double sigma, int property_count, int total_reference_count, int
class_count,
38                          pnn_class ** pnn_class_arr);
39 pnn_data * pnn_data_free(pnn_data * obj);
40
41 pnn_data * pnn_data_load(FILE * f);
42 void pnn_data_fprint(pnn_data * data, FILE * f);
43
44 typedef struct
45 {
46     char * class_name;
47     double prediction;
48 }
49 pnn_prediction;
50
51 typedef struct
52 {
53     char * class_name;
54     double accuracy;
55 }
56 pnn_evaluation;
57
58 pnn_prediction * pnn_predict(pnn_data * data, double * input);
59 pnn_evaluation * pnn_evaluate(pnn_data * net, pnn_data * data);
60
```

data-processing.py

```
1 import pandas as pd
2 import numpy as np
3 from sklearn.preprocessing import LabelEncoder
4 from sklearn.model_selection import train_test_split
5 from shutil import rmtree
6 from os.path import exists, isdir
7 from os import makedirs
8
9 DATA_NAME = "original_data.csv"
10 OUT_DATA_PREFIX = "/data"
11 PNN_OUTPUT_DIR = "./out-pnn"
12 PNN_REFERENCE_OUTPUT_DIR = PNN_OUTPUT_DIR + OUT_DATA_PREFIX
13 TRAIN_OUTPUT_DIR = "./out-train"
14 TRAIN_REFERENCE_OUTPUT_DIR = TRAIN_OUTPUT_DIR + OUT_DATA_PREFIX
15 TEST_OUTPUT_DIR = "./out-test"
16 TEST_REFERENCE_OUTPUT_DIR = TEST_OUTPUT_DIR + OUT_DATA_PREFIX
17
18 PNN_REFERENCE_COUNT_BY_CLASS = {
19     "smurf": 0.6,
20     "neptune": 0.6,
21     "normal": 0.6,
22     "back": 1.0,
23     "satan": 1.0,
24     "ipsweep": 1.0,
25     "portsweep": 1.0,
26     "warezclient": 1.0,
27     "teardrop": 1.0,
28     "pod": 1.0,
29     "nmap": 1.0,
30     "guess_passwd": 1.0,
31     "buffer_overflow": 1.0,
32     "land": 1.0,
33     "warezmaster": 1.0,
34     "imap": 1.0,
35     "rootkit": 1.0,
36     "loadmodule": 1.0,
37     "ftp_write": 1.0,
38     "multihop": 1.0,
39     "phf": 1.0,
40     "perl": 1.0,
41     "spy": 1.0
42 }
43 TEST_SIZE = 0.25
44 REAL_DATA_COUNT_PER_CLASS = 8000
45 RANDOM_STATE = 1450
46
47 # Read data
48 data = pd.read_csv(DATA_NAME)
49
50 # Show column info
51 print(">>> Original data >>>")
52 for column in data.columns:
53     unique_values_count = data[column].nunique()
```



```
54     unique_values = data[column].unique()
55     print(f"Column: {column}")
56     print(f"Unique Values Count: {unique_values_count}")
57     print(f"Unique Values: {unique_values}")
58     print()
59 print(">>> Column types >>>\n", data.dtypes, "\n")
60
61 # Show unique classes and their count
62 print(">>> Class | Count >>>")
63 print(data["label"].value_counts(), "\n")
64
65 # Drop lnum_outbound_cmds and is_host_login columns since values are same for all rows
66 data = data.drop(columns = ["lnum_outbound_cmds", "is_host_login"])
67
68 # Convert protocol_type, service, flag columns to numeric
69 nonnumeric_columns = ["protocol_type", "service", "flag"]
70 label_encoder = LabelEncoder()
71 for column in nonnumeric_columns:
72     data[column] = label_encoder.fit_transform(data[column])
73
74 # normalize data
75 for column_name in data.columns:
76     if column_name != 'label':
77         column = data[column_name]
78         min_val = column.min()
79         max_val = column.max()
80         data[column_name] = (column - min_val) / (max_val - min_val)
81
82 # Show column info
83 print(">>> Data: removed useless columns, all numeric >>>")
84 for column in data.columns:
85     unique_values_count = data[column].nunique()
86     unique_values = data[column].unique()
87     print(f"Column: {column}")
88     print(f"Unique Values Count: {unique_values_count}")
89     print(f"Unique Values: {unique_values}")
90     print()
91 print(">>> Column types >>>\n", data.dtypes, "\n")
92
93 # Show unique classes and their count
94 print(">>> Class | Count >>>")
95 print(data["label"].value_counts(), "\n")
96
97 # Delete old run data and recreate out directory tree
98 if exists(PNN_OUTPUT_DIR):
99     rmtree(PNN_OUTPUT_DIR)
100 makedirs(PNN_REFERENCE_OUTPUT_DIR)
101 if exists(TRAIN_OUTPUT_DIR):
102     rmtree(TRAIN_OUTPUT_DIR)
103 makedirs(TRAIN_REFERENCE_OUTPUT_DIR)
104 if exists(TEST_OUTPUT_DIR):
105     rmtree(TEST_OUTPUT_DIR)
106 makedirs(TEST_REFERENCE_OUTPUT_DIR)
107
108 # data export
109 property_count = len(data.columns.tolist()) - 1
```

```

110 data.insert(0, "property_count", property_count)
111 rows_by_class = dict(tuple(data.groupby("label")))
112 count_by_class = { "pnn": 0, "train" : 0, "test": 0 }
113 for k,k_data in rows_by_class.items():
114     k_data.drop(columns = ["label"], inplace = True)
115     if k_data.shape[0] > REAL_DATA_COUNT_PER_CLASS:
116         # select real count from k_data
117         k_data_real = k_data.sample(n = REAL_DATA_COUNT_PER_CLASS, random_state =
RANDOM_STATE)
118
119         # split
120         k_data_train, k_data_test = train_test_split(k_data_real, test_size = TEST_SIZE,
random_state = RANDOM_STATE)
121
122         # take pnn data from train data
123         k_data_pnn = k_data_train.sample(frac = PNN_REFERENCE_COUNT_BY_CLASS[k], random_state
= RANDOM_STATE)
124
125         # save data
126         count_by_class["pnn"] += k_data_pnn.shape[0]
127         k_data_pnn.to_csv(PNN_REFERENCE_OUTPUT_DIR + "/" + k + "-" + str(k_data_pnn.shape[0])
+ ".csv",
128                             header = False, index = True, lineterminator = ',')
129         count_by_class["train"] += k_data_train.shape[0]
130         k_data_train.to_csv(TRAIN_REFERENCE_OUTPUT_DIR + "/" + k + "-" +
str(k_data_train.shape[0]) + ".csv",
131                             header = False, index = True, lineterminator = ',')
132         count_by_class["test"] += k_data_test.shape[0]
133         k_data_test.to_csv(TEST_REFERENCE_OUTPUT_DIR + "/" + k + "-" +
str(k_data_test.shape[0]) + ".csv",
134                             header = False, index = True, lineterminator = ',')
135     else:
136         # save whole data as pnn, train, test
137         count_by_class["pnn"] += k_data.shape[0]
138         k_data.to_csv(PNN_REFERENCE_OUTPUT_DIR + "/" + k + "-" + str(k_data.shape[0]) + "
.csv",
139                             header = False, index = True, lineterminator = ',')
140         count_by_class["train"] += k_data.shape[0]
141         k_data.to_csv(TRAIN_REFERENCE_OUTPUT_DIR + "/" + k + "-" + str(k_data.shape[0]) + "
.csv",
142                             header = False, index = True, lineterminator = ',')
143         count_by_class["test"] += k_data.shape[0]
144         k_data.to_csv(TEST_REFERENCE_OUTPUT_DIR + "/" + k + "-" + str(k_data.shape[0]) + "
.csv",
145                             header = False, index = True, lineterminator = ',')
146
147 # save metadata
148 with open(PNN_OUTPUT_DIR + "/info.csv", "w", newline = "\n") as info:
149     info.write(",".join([str(property_count),
150                             str(count_by_class["pnn"]),
151                             str(len(data["label"].unique()))]))
152 with open(TRAIN_OUTPUT_DIR + "/info.csv", "w", newline = "\n") as info:
153     info.write(",".join([str(property_count),
154                             str(count_by_class["train"]),
155                             str(len(data["label"].unique()))]))
156 with open(TEST_OUTPUT_DIR + "/info.csv", "w", newline = "\n") as info:
157     info.write(",".join([str(property_count),
158                             str(count_by_class["test"]),

```

159 |

```
str(len(data["label"].unique()))))
```